

Vorlesung

Mensch-Maschine-Interaktion

WS 2024/2025



Kapitel I.

Eingabesensorik

Priv.-Doz. Dr. Frank Weichert
Lehrstuhl für Computergraphik (Informatik VII)
Technische Universität Dortmund
<https://graphics.cs.tu-dortmund.de>

Hinweis:

„Der Nutzerin/dem Nutzer ist bekannt, dass die nachfolgenden Inhalte und Materialien urheberrechtlich geschützt sind. Die Nutzung ist ausschließlich für den persönlichen Gebrauch im Rahmen von universitären Zwecken zulässig. Insbesondere ist die Vervielfältigung, Bearbeitung, Verbreitung und jede Art der Verwertung sowie die Weitergabe an Dritte nicht gestattet. Zuwiderhandlungen werden zivil- und strafrechtlich verfolgt.“

I. Eingabesensorik

Übersicht



I.1. Einleitung



- I.1.1. Mensch-Maschine-Interaktionsmodell
- I.1.2. Eingabesensoren und Eingabegeräte
- I.1.3. Handorientierte Eingabegeräte
- I.1.4. Bewegungsverfolgung
- I.1.5. Sensordatenverarbeitung

I.2. Digitale Bildverarbeitung

- I.2.1. Einleitung
- I.2.2. Bildaufnahme
- I.2.3. Bildrestauration
- I.2.4. Bildverbesserung
 - I.2.4.1. Punktoperatoren
 - I.2.4.2. Lokale Operatoren im Ortsbereich
 - I.2.4.3. Diskrete Fouriertransformation
 - I.2.4.4. BV im Ortsfrequenzbereich
- I.2.5. Segmentierung
 - I.2.5.1. Einleitung
 - I.2.5.2. Bereichsorientierte Verfahren
 - I.2.5.3. Kantenorientierte Verfahren

I.3. Mustererkennung

- I.3.1. Grundkonzept
- I.3.2. Merkmale
- I.3.3. Klassifikation
- I.3.4. Neuronale Netze
 - I.3.4.1. Multilayer Feedforward NNs
 - I.3.4.2. Convolutional NNs
 - I.3.4.3. Sprachmodelle und GPT
 - I.3.4.4. Bemerkungen



**Eingabesensorik:**

- **Sensor:** Gerät zur Erfassung von physikalischen Signalen der Umwelt
- **Sensortypen:**
 - *elektrooptische Sensoren:* Fotozelle, CCD-Chip
 - *elektromechanische Sensoren:* Potenziometer, Schalter, Dehnstreifen, Drehmomentsensor
 - *elektromagnetische Sensoren:* Antennen
 - *elektroakustische Sensoren:* Mikrofon
- **Eingabegerät:** Kombination von Sensoren zur Erfassung von Information vom Anwender des Systems

**Handorientierte Eingabegeräte:****Beispiele:**

- Tastatur
- Maus (mechanisch, optisch)
- Track-Ball (Rollkugel)
- Joystick
- Paddles
- Space-Ball
- Lichtgriffel
- Datentablett
- Tastbildschirm
- Datenhandschuh



Track-Ball (2D)



Paddles (3D)



Space-Ball



Datentablett (2D)

Optische Maus




Funktionsweise:

- Beleuchtung der Tischfläche durch eine Leuchtdiode.
- Reflexion des Lichts von der Tischfläche auf einen CMOS-Sensor, der Bilder aufnimmt.
- Verarbeitung der Bilder durch einen digitalen Signalprozessor (DSP), der Muster in den Bildern extrahiert und feststellt wie sich die Muster von Bild zu Bild bewegt haben.
- Aus der Verschiebung werden die neuen Koordinaten bestimmt und an den Rechner weitergegeben.

Tastbildschirm


Funktionsweise:

- Rahmen um den Bildschirm, auf dem auf einer horizontalen und vertikalen Seite Infrarot-Lichtquellen und auf der gegenüberliegenden Seite Fotosensoren angebracht sind.
- Durch Berühren des Bildschirmes werden horizontale und vertikale Strahlen unterbrochen, welche die Lokalisierung erlauben.





andere Techniken:

- Ultraschallwellen, mit denen das Monitorglas angeregt wird
 - kapazitive Technik, bei der eine spezielle Folie auf den Bildschirm aufgebracht ist.
- Nachteil:** Verschmutzung des Bildschirms durch Fingerabdrücke



Tastbildschirm



Datenhandschuh (data glove)


Funktionsweise: Handschuh mit Sensoren zur Erfassung der Handpostur

Biegesensoren:

- Glasfaserkabel mit einer Leuchtdiode an einem Ende und einer Fotozelle am anderen Ende.
- Die Oberfläche des Kabels ist an den Stellen angeraut, wo es für Verbiegung sensitiv sein soll.
- Abhängig von der Verbiegung ändert sich der Betrag des übertragenen Lichts.

Tastsensoren:

z.B. realisiert durch Schalter



**Aufgabe der Bewegungsverfolgung (Motion Tracking):**

Bestimmung von Ort und Orientierung eines starren Objekts im Raum.

Einsatzbeispiele:

Eingabe über größere Distanzen, z.B. in einer projektionsbasierten immersiven Umgebung.

Erfassung der Blickrichtung eines Benutzers in einer projektionsbasierten immersiven Umgebung

Lokalisierung portabler Geräte bei Augmented Reality-Anwendungen



s. Kapitel H. „Virtuelle/Augmentierte Realität“

**Leistungsmerkmale**

- Räumliche Abweichung
- Räumliches Rauschen (jitter)
- Stabilität oder Abwandern (creep)
- Latenz bzw. Latenzschwankungen
- andere dynamische Fehler

Gerätetypen für die Bewegungsverfolgung

- mechanische Bewegungsverfolgung
- drehmomentbasierte Bewegungsverfolgung (Gyroskop)
- akustische Bewegungsverfolgung
- elektromechanische Bewegungsverfolgung
- optische Bewegungsverfolgung
- radio- und mikrowellenbasierte Bewegungsverfolgung (z.B. GPS)

Mechanische Sensoren


Arbeitsweise:

direkte physische Verbindung zwischen dem verfolgten Objekt und dem Auswertesystem.

Beispiel:

roboterarmähnliche Konstruktion, bei denen durch elektromagnetische Übertragungseinheiten, die etwa in den Gelenken eingebaut sind, beispielsweise Potentiometer, die Gelenkstellung erfasst wird


BOOM = Binocular Omni-Orientation Monitor: Stereodisplay mit mechanischer Lokalisierung



Drehmomentsensoren (inertial sensing)

Arbeitsweise: Kombination aus Gyroskopen und Beschleunigungsmessern

- *Gyroskop (Kreiselkompass)*: Messung der räumlichen Ausrichtung
- *Beschleunigungsmesser*: werden zur Ortsbestimmung verwendet



Stärke: klein, keine Emitter, keine Felder, sehr geringe Latenz, gute Voraussagemöglichkeit, extrem geringes Rauschen.

Schwäche: hoher Drift (örtliche Abweichung)



Produktinformation: Intersense, <http://www.isense.com>

Drehmomentsensoren (inertial sensing)**Bsp. Nintendo Wii****Magnetische Sensoren***Arbeitsweise:*

Lage- und Orientierungssensor

Messung des lokalen Magnetfeldvektors am Sensor durch Magnetometer (für ein quasi-statisches direktes Flussfeld) oder Stromfluss in einer magnetischen Spule (dynamisches Magnetfeld einer aktiven Quelle)

Möglichkeiten für das zu messende Magnetfeld:

- Verwendung des Erdmagnetfeldes mit Korrekturtabelle
- Erzeugung eines Magnetfeldes mit einer Multi-Spulen-Quelle und Messung von Ort und Orientierung mit drei Antennen

Nachteile:

- ungenau
- störende Kabel
- Elektrosmog



Bsp.: Tracking der Brille und des Eingabestiftes des linken Benutzers

Optische Sensoren


Arbeitsweise:

- Messung von reflektiertem oder emittiertem sichtbarem oder Infrarot-Licht;
- drei Komponenten: Lichtquellen, optische Sensoren und eventuell reflektierende Markierer



Kamera mit Infrarotlichtquelle (Leuchtdiodenarray)

Beispiele von verfolgten Geräten mit reflektierenden Markierern





Stereokamerakonfiguration zur räumlichen Objekterfassung



Produktinformation: Advanced Real Time Tracking GmbH: www.ar-trackinl.de

Optische Sensoren




Produktinformation: OptiTrack - Motion Capture Systems
<https://optitrack.com>

Vorteile:

- bei Verwendung von Markieren genau
- keine Kabel, kein Elektroschmog

Nachteile:


- Verdeckungen zwischen Kamera(s) und verfolgtem Objekt müssen vermieden werden
- Falls keine Markierer und spezielle Beleuchtung verwendet werden, Schwierigkeiten bei der Bildanalyse, insbesondere aufgrund von sich änderndem Umgebungslicht und der notwendigen Identifikation des verfolgten Objekts.

Bsp.: Markierfreie Verfolgung**Distanzsensoren**

Bestimmung eines Entfernungsbildes (Tiefenbild, z-Bild)

Arbeitsweisen:

- Laser-Scanner
- Time-of-Flight (TOF)-, PMD-Kameras:
 - Aussenden von Lichtpulsen, Bestimmung der Entfernung aus der Verzögerung des Lichtes, das von dem zu erfassenden Objekt reflektiert wird.
- Strukturiertes Licht:
 - Verwendung der Verzerrung von Projektionsmustern

**Beispiel eines Tiefenbildes**

QUELLE: <https://de.wikipedia.org/wiki/TOF-Kamera>

Beispiel: Microsoft Kinect

Fragestellungen, Ziele, Anwendungsfälle

Bildklassifikation




Bildersuche(-retrieval)




Fragestellungen, Ziele, Anwendungsfälle

Objekterkennung




Segmentierung




Fragestellungen, Ziele, Anwendungsfälle

Videoklassifikation



Aktions-/Gestenerkennung



Skelett-basierte Posenerkennung



Fragestellungen, Ziele, Anwendungsfälle

Image Captioning



A white teddy bear
sitting in the grass



A man in a baseball
uniform throwing a ball



A woman is holding
a cat in her hand



A man riding a wave
on top of a surfboard




A cat sitting on a
suitcase on the floor




A woman standing on a
beach holding a surfboard

Fragestellungen, Ziele, Anwendungsfälle




Semantischer raum-zeitlicher Szenengraph



Fragestellungen, Ziele, Anwendungsfälle

Semantische Bildsynthese





Signalverarbeitungspipeline

Schwierigkeiten/Aufgaben

Signalgewinnung

Signalaufnahme

Informationsverlust, Rauschen, Messfehler

Signaldiskretisierung

Beachtung des Abtasttheorems zur Vermeidung von Alias-Effekten

Signalrestauration

modellbasierte Minderung der Fehler der Signalaufnahme

Signalbearbeitung

Signalverbesserung

anwendungsbezogene Minderung der Fehler der Signalaufnahme und Aufbereitung für die Segmentierung

Signalsegmentierung

Vorbereitung der Signalerkennung, Zerlegung in Teilsignale

Signalerkennung

Merkmalsextraktion

Zuordnung von Merkmalen zu den Teilsignalen

Klassifikation/Synthese

anwendungsbezogene Klassifikation/Synthese der Teilsignale (anhand der Merkmale)

Signalinterpretation

anwendungsbezogene Interpretation, Abstraktion



Ergebnis der Signalverarbeitungspipeline:

- Zeichen, Wert, Position, Ton, Bild
- als Einzelwert oder als Wertfolge

Leistungsmerkmale der Sensordatenverarbeitung

- Abweichung Soll-Ist-Signal
- Latenz, Latenzschwankungen

Im Folgenden:

- Digitale Bildverarbeitung als Beispiel
- Spezielle Aspekte zeitabhängiger Signale

**I.1. Einleitung**

- I.1.1. Mensch-Maschine-Interaktionsmodell
- I.1.2. Eingabesensoren und Eingabegeräte
- I.1.3. Handorientierte Eingabegeräte
- I.1.4. Bewegungsverfolgung
- I.1.5. Sensordatenverarbeitung

I.2. Digitale Bildverarbeitung

- I.2.1. Einleitung
- I.2.2. Bildaufnahme
- I.2.3. Bildrestauration
- I.2.4. Bildverbesserung
 - I.2.4.1. Punktoperatoren
 - I.2.4.2. Lokale Operatoren im Ortsbereich
 - I.2.4.3. Diskrete Fouriertransformation
 - I.2.4.4. BV im Ortsfrequenzbereich
- I.2.5. Segmentierung
 - I.2.5.1. Einleitung
 - I.2.5.2. Bereichsorientierte Verfahren
 - I.2.5.3. Kantenorientierte Verfahren

I.3. Mustererkennung

- I.3.1. Grundkonzept
- I.3.2. Merkmale
- I.3.3. Klassifikation
- I.3.4. Neuronale Netze
 - I.3.4.1. Multilayer Feedforward NNs
 - I.3.4.2. Convolutional NNs
 - I.3.4.3. Sprachmodelle und GPT
 - I.3.4.4. Bemerkungen

**Gegenstand der digitale Bildverarbeitung:**

Bearbeitung von Bildern mit Digitalrechnern mit unterschiedlichen Zielen, z.B.



- Bildmanipulation
- Bildverstehen
- bildbasierte Sensoren


Weitere Details s. Vorlesung „Digitale Bildverarbeitung“**QUELLEN:**

R.C. Gonzalez, R.E. Woods, Digital Image Processing, 4. Aufl., Prentice Hall, 2017

F.M. Wahl, Digitale Bildsignalverarbeitung, Springer-Verlag, 1989, (2. Aufl.)

Stufen der Bildverarbeitung und Bilderkennung:



Beispiel für einen Sensor: CCD-Chip**Schwierigkeit bei der Digitalisierung: Alias-Effekte**

Vermeidung: Beachten des Abtasttheorems, s. Kapitel C.4.4

Bildrestauration:

Verbesserung von Bildsignalen im Sinne quantitativ definierter Kriterien (im Gegensatz zu den subjektiven Kriterien bei der Bildverbesserung).

Vorgehensweise bei der Bildrestauration:

1. Definition eines Signalmodells, das den Zusammenhang zwischen der die Bildszene repräsentierten Helligkeitsverteilung (zu erfassende Szene) und dem mit Hilfe eines technischen Systems gewonnenen Bildsignal (Ergebnis der Szenenerfassung) wiedergibt.
2. (Näherungsweise) Rückrechnung des Originalsignals aus dem gewonnenen Signal mit Hilfe des Signalmodells.

Beispiel für ein einfaches Signalmodell:

$$\nearrow \tilde{f}(x, y) = \int \int f(\xi, \eta) h(x - \xi, y - \eta) d\xi d\eta + r(x, y)$$


erfasstes Ausgabesignal ↑ zu erfassendes Eingangssignal

im Ortsfrequenzbereich:

$$\tilde{\tilde{F}}(u, v) = F(u, v) \cdot H(u, v) + R(u, v)$$

wobei h (H) die sogenannte *Modulationsübertragungsfunktion* mit Tiefpasscharakteristik ist (z.B. für das Verhalten der Sensorelemente eines CCD-Chips)

und r (R) eine Zufallsfunktion ist (z.B. für das „Rauschen“ der Sensorelemente eines CCD-Chips)

**Möglichkeit zur Bestimmung von $h(x, y)$ bzw. $H(u, v)$:**

Verwendung von einfachen Testbildern

Bestimmung von $r(x, y)$ bzw. $R(u, v)$:

nicht möglich, jedoch möglicherweise Abschätzung der mittleren spektralen

Störleistungen $|R(u, v)|^2$ aus den Leistungsspektren $|\tilde{\tilde{F}}(u, v)|^2$

bei einer schwarzen Aufnahme.



Signalmodell: $\tilde{F}(u, v) = F(u, v) \cdot H(u, v) + R(u, v)$

Bildrestauration:

Gegeben: $\tilde{F}(u, v)$ erfasstes Ausgabesignal

Gesucht: $F(u, v)$ zu erfassendes Eingangssignal

Schwierigkeit:

Nullstellen von $H(u, v)$ verhindern die exakte Restauration, selbst wenn das Rauschen wegfällt.

Vorgehensweise:

Bestimmung von Näherungslösungen, basierend auf dem digitalen Bild

→ Kontinuierliche wird durch die diskrete Fouriertransformation ersetzt



Beispiele:

- • amplitudenbegrenztes inverses Filter
- Nebenbedingungsfilter
- Wiener-Filter



- **inverses Filter (diskret):** $\hat{F}(k, l) = \tilde{F}(k, l)H(k, l)^{-1}$

- **amplitudenbegrenztes inverses Filter:**

inverses Filter, bei dem die Amplitude von $H(k, l)^{-1}$ durch eine Konstante begrenzt wird.

Bsp.: Amplitudenbegrenztes inverses Filter


Betragsquadrate der
Übertragungsfunktion



Originales,
gestörtes und
restauriertes
Leistungsspektrum

Bsp.:


Originalbild:





Generierung eines Ausgabetestbildes:

1. Verunschärfung im Ortsbereich mit einem 2D-Spalttiefpass mit 5×5 Abtastwerten Ausdehnung:



2. Quantisierung mit 8 Bit liefert einen kleinen zufällige Rundungsfehler von max. $2 \cdot 10^{-3}$, der als überlagertes gleichverteiltes Rauschen aufgefasst werden kann.




Restauration durch inverse Bildfilterung:

Anwendung einer dem Spalttiefpass inversen Übertragungsfunktion

$$H(k, l)^{-1} = [\text{si}(\pi \Delta m k / M) \text{si}(\pi \Delta n l / N)]^{-1}$$

mit $\Delta m = \Delta n = 5$ im Ortsfrequenzbereich.




↪ hochfrequente periodische Störmuster




Restauration durch amplitudenbegrenztes inverses Filter:

Amplitudenbegrenzung des
inversen Filters, hier auf 25
(willkürlich):



Originalbild:



I.1. Einleitung

- I.1.1. Mensch-Maschine-Interaktionsmodell
- I.1.2. Eingabesensoren und Eingabegeräte
- I.1.3. Handorientierte Eingabegeräte
- I.1.4. Bewegungsverfolgung
- I.1.5. Sensordatenverarbeitung

I.2. Digitale Bildverarbeitung

- I.2.1. Einleitung
- I.2.2. Bildaufnahme
- I.2.3. Bildrestauration
- I.2.4. Bildverbesserung
 - I.2.4.1. Punktoperatoren
 - I.2.4.2. Lokale Operatoren im Ortsbereich
 - I.2.4.3. Diskrete Fouriertransformation
 - I.2.4.4. BV im Ortsfrequenzbereich
- I.2.5. Segmentierung
 - I.2.5.1. Einleitung
 - I.2.5.2. Bereichsorientierte Verfahren
 - I.2.5.3. Kantenorientierte Verfahren

I.3. Mustererkennung

- I.3.1. Grundkonzept
- I.3.2. Merkmale
- I.3.3. Klassifikation
- I.3.4. Neuronale Netze
 - I.3.4.1. Multilayer Feedforward NNs
 - I.3.4.2. Convolutional NNs
 - I.3.4.3. Sprachmodelle und GPT
 - I.3.4.4. Bemerkungen

I.4. Verarbeitung zeitabhängiger Signale

- I.4.1. Zeitabhängige Signale
- I.4.2. Filterung zeitabhängiger Signale

**Ziel der Bildverbesserung:**

Bildsignale so aufbereiten, dass die für eine gestellte Aufgabe relevante Information besser visuell bzw. maschinell extrahiert werden kann.

Anwendung von subjektiven, problemabhängigen Kriterien, die das Signal auch völlig verändern können.

Bsp.: Hochpassfilter, um so feinstrukturierte Details im verarbeiteten Bild zu verdeutlichen und auf diese Weise die visuelle Interpretation zu erleichtern.

Im Folgenden – vier Basiskonzepte

- A. Punktoperatoren
- B. Lokale Operatoren im Ortsbereich
- C. Diskrete Fouriertransformation
- I. Bildverbesserung im Ortsfrequenzbereich

**Schwierigkeit:**

Es gibt eine unüberschaubar große Anzahl publizierter Verfahren, die oft ähnlich sind.

grundsätzliche Klassifikation der Verfahren:

- Ortsbereichsverfahren
- Ortsfrequenzbereichsverfahren
- signalunabhängige / signalabhängige Verfahren
- lineare / nichtlineare Methoden

im Folgenden: Beispiele, um die Wirkungsweise von Verarbeitungsoperatoren bei unterschiedlichen Aufgaben zu sehen.

Ein **Punktoperator** verändert den Intensitätswert eines Punktes nur in Abhängigkeit von dessen Intensität.

Beispiel: Histogrammglättung

Ziel: Intensitätswerte des transformierten Bildes möglichst gleichmäßig über den gesamten zur Verfügung stehenden Grauwertbereich $0 \leq f \leq Q-1$ verteilen.



Originalbild



verarbeitetes Bild

Intensitätshistogramm:

gibt für jeden Grauwert eines Bildes (z.B. Grauwertbild mit $Q=256$ Quantisierungsstufen) die Anzahl seines Auftretens an:

$$h(f) = \sum_{m=0}^{M-1} \sum_{n=0}^{N-1} \delta(f(m, n) - f)$$


mit

$$\delta(\xi) = \begin{cases} 1 & \text{für } \xi = 0 \\ 0 & \text{sonst,} \end{cases}$$



d.h. $h(f)$ ist die Anzahl des Auftretens der Intensität f im Bild

$$f(m, n), \quad m = 0, \dots, M-1, \quad n = 0, \dots, N-1.$$

Bsp.: Intensitätshistogramme eines RGB-Bildes:




Anpassung von Intensitätshistogrammen



Auto-Kontrast-Anpassung

- Vordefinierte Quantile p_{lo} und p_{hi}
- Lineare Anpassung der Zwischenwerte

Anpassung von Intensitätshistogrammen





Transformation der Histogrammglättung:

$$f' = (Q-1) \cdot H(f) = \frac{Q-1}{MN} \sum_{\xi=0}^f h(\xi), f = 0, \dots, Q-1$$


mit der **kumulativen Verteilungsfunktion**

$$H(f) := \frac{1}{MN} \sum_{\xi=0}^f h(\xi).$$




Bsp.: Korrespondierende Histogramme

korrespondierende Intensitätsverteilungsfunktionen

Prinzip von Filtern


Jeder neue Pixelwert $I'(u, v)$ wird berechnet als eine Funktion der Pixelwerte innerhalb einer bestimmten Region von Quellpixeln $R_{u,v}$ im Originalbild I berechnet.

Lokale Operatoren bilden die Intensitätswerte $f(i, j)$ innerhalb eines lokalen Bildbereichs (Fenster) W_{mn} gemäß eines definierten Funktionalzusammenhangs (Filterkern) $O[.]$ in die Ausgabebildelemente $g(m, n)$ ab, d.h.



$$g(m, n) = O[\{f(i, j) \mid (i, j) \in W_{m,n}\}].$$

Lokale Operatoren bilden die Intensitätswerte $f(i, j)$ innerhalb eines lokalen Bildbereichs (Fenster) W_{mn} gemäß eines definierten Funktionalzusammenhangs (Filterkern) $O[.]$ in die Ausgabebildelemente $g(m, n)$ ab, d.h.



**gebräuchliche Fensterformen:**

rechteckige Fenster:


$$W_{mn} = \{(i, j) \mid m - \Delta m \leq i \leq m + \Delta m, n - \Delta n \leq j \leq n + \Delta n\}$$



kreuzförmige Fenster:


$$W_{mn} = \{(i, j) \mid (m - \Delta m \leq i \leq m + \Delta m \text{ und } j = n)$$

$$\text{oder } (i = m \text{ und } n - \Delta n \leq j \leq n + \Delta n)\}$$



kreisförmige Fenster:

$$W_{mn} = \{(i, j) \mid \sqrt{(m - i)^2 + (n - j)^2} \leq r\}$$

**häufig:** Hintereinanderschalten von Operatoren

~> Vergrößerung des Einflussbereichs

Bem.: Lokale Operatoren eignen sich für Parallelverarbeitung**Faltung**

$$g(m, n) := f(m, n) ** h(m, n) := \sum_{\xi=0}^{M-1} \sum_{\eta=0}^{N-1} f(\xi, \eta) h(m - \xi, n - \eta)$$

wobei

 $f(m, n)$ das gegebene Bild $h(m, n)$ der Filterkern $g(m, n) := f(m, n) * h(m, n)$ die **Faltung** von

$$f : \{(m, n) \mid 0 \leq m \leq M_f - 1, 0 \leq n \leq N_f - 1\} \rightarrow \mathbb{R} \quad (C)$$

$$h : \{(m, n) \mid 0 \leq m \leq M_h - 1, 0 \leq n \leq N_h - 1\} \rightarrow \mathbb{R} \quad (C)$$



$$M := M_f + M_h - 1, N := N_f + N_h - 1,$$

Die Summanden mit Faktoren außerhalb des Definitionsbereichs der Funktionen werden nicht ausgewertet.


Beispiel: Lineare Tiefpassfilter

Kompensation breitbandiger Störungssignale, die von Quanten-, Sensor-, Übertragungs-, Quantisierungsrauschen usw. herrühren.

Bsp.:

**Rauschreduktion (Denoising) mittels Tiefpassfilterung**

Relevante Strukturen, z.B. Kanten (grün) oder dünne Linien (blau) werden verbreitert, der lokale Kontrast wird verringert.



Original

Filteranwendung

Originalbild:**Testbild:**

additive Überlagerung des Originals mit weißem gaußschen Rauschen, d.h. näherungsweise Gauß-förmige Amplitudenverteilung und näherungsweise konstantes Leistungsspektrum.

**Faltung mit****Spalttiefpass:****Gaußtiefpass:****Kegeltiefpass:****Nachteil der Tiefpassfilter:**

Kompromiss zwischen der Unterdrückung des dem Bildsignal überlagerten Rauschens einerseits und der Erhaltung feiner Bildschirmstrukturen andererseits.



Beispiel für einen nichtlinearen Operator: Medianfilter

Medianfilter: von den p Elementen eines Operatorfensters wird der $p/2$ -größte Wert genommen.

~>

der Medianfilter beseitigt alle Strukturen vollständig, deren Ausdehnung innerhalb des Operatorfensters nicht mehr als $(p-2)/2$ Bildpunkte betragen, z.B. Linien, Punkte, Ecken, etc. Hell/Dunkelkanten bleiben erhalten.

Bsp.:



Beispiel: Lineare Hochpassfilter

Hervorheben hochfrequenter Details wie kleine Objekte oder Hell/Dunkelkanten, aber auch evtl. überlagerte Störungen wie Signalrauschen.

- Eingangssignal $f(m, n)$ mittels Glättungsoperator $h_{TP}(m, n)$ glätten:

$$f_{TP}(m, n) = f(m, n) * h_{TP}(m, n)$$

- Subtraktion von einem Vielfachen $c > 0$ des Eingangssignals:

$$f_{HP}(m, n) = c \cdot f(m, n) - f_{TP}(m, n)$$

$$\leadsto f_{HP}(m, n) = f(m, n) * [c \cdot \delta(m, n) - h_{TP}(m, n)]$$

$$= f(m, n) * h_{HP}(m, n)$$

**Bsp.:**

unscharf aufgenommenes Objekt:



Verschärfung:



Verschärfung: $c = 2$, Spalttiefpass
mit $\Delta m = \Delta n = 7$.

**Eindimensionale diskrete Fouriertransformation (DFT):**einer Funktion $f : \{m \mid m = 0, 1, \dots, M - 1\} \rightarrow \mathbb{R}$:

$$F(k) := \sum_{m=0}^{M-1} f(m) \cdot \exp[-2\pi i(km/M)],$$

$$k = 0, \dots, M - 1, \quad i := \sqrt{-1}$$

$$\exp[i\alpha] = \cos \alpha + i \sin \alpha.$$

Inverse eindimensionale DFT:

$$f(m) := \frac{1}{M} \sum_{k=0}^{M-1} F(k) \cdot \exp[2\pi i(km/M)],$$

$$m = 0, \dots, M - 1.$$



Beweis der Formel der inversen Fouriertransformation:

$$\frac{1}{M} \sum_{k=0}^{M-1} \left[\sum_{m'=0}^{M-1} f(m') \cdot \exp[-2\pi i(km'/M)] \right] \cdot \exp[2\pi i(km/M)] =$$

$$\frac{1}{M} \sum_{m'=0}^{M-1} f(m') \cdot \sum_{k=0}^{M-1} \exp[2\pi i(k(m-m')/M)] = f(m)$$

$$\text{da} \quad \sum_{k=0}^{M-1} \exp[2\pi i(k(m-m')/M)] = \begin{cases} 0 & \text{für } m \neq m' \\ M & \text{für } m = m' \end{cases}$$





Interpretation der FT als Summe von Schwingungen:

Falls die Funktion f reell ist, beschreibt die diskrete Fourier-Transformation die Darstellung von f als gemittelte Summe von diskretisierten sinusförmigen Schwingungen unterschiedlicher Frequenz und Phase:

$F(k)$ bedeutet, dass die Schwingung der Frequenz k mit der Amplitude $|F(k)|/M$ und der Phasenverschiebung $\phi(k)$ in f auftritt, wobei

$$F(k) = |F(k)| \exp[i\phi(k)].$$

Applet: Vorlesungswebseite





Beweis: (M ungerade vorausgesetzt):

Dabei wird verwendet, dass

$$\begin{aligned} \text{a) } \bar{F}(k) &= \sum_{m=0}^{M-1} f(m) \cdot \exp[2\pi i(km/M)] = \\ &= \sum_{m=0}^{M-1} f(m) \cdot \exp[2\pi i((k-M)m/M)] = \\ &= \sum_{m=0}^{M-1} f(m) \cdot \exp[-2\pi i((M-k)m/M)] = F(M-k) \end{aligned}$$

$$\text{b) } F(k) = |F(k)| \exp(i\phi(k))$$

$$\text{c) } \exp[i\alpha] + \exp[-i\alpha] = 2 \cos \alpha.$$



Beweis: (M ungerade vorausgesetzt):

$$\begin{aligned} f(m) &:= \frac{1}{M} \sum_{k=0}^{M-1} F(k) \cdot \exp[2\pi i(km/M)] = \\ &= \frac{1}{M} F(0) + \frac{1}{M} \sum_{k=1}^{(M-1)/2} F(k) \cdot \exp[2\pi i(km/M)] + \\ &= \frac{1}{M} \sum_{k=1}^{(M-1)/2} F(M-k) \cdot \exp[2\pi i(M-k)m/M] = \\ &= \frac{1}{M} F(0) + \frac{1}{M} \sum_{k=1}^{(M-1)/2} [F(k) \cdot \exp[2\pi i(km/M)] + \boxed{F(M-k)} \cdot \exp[2\pi i(M-k)m/M]] = \\ &= \frac{1}{M} F(0) + \frac{1}{M} \sum_{k=1}^{(M-1)/2} [\boxed{F(k)} \cdot \exp[2\pi i(km/M)] + \boxed{\bar{F}(k)} \cdot \exp[2\pi i(-k)m/M]] = \\ &= \frac{1}{M} F(0) + \frac{1}{M} \sum_{k=1}^{(M-1)/2} [\boxed{|F(k)|} \exp[2\pi i(km/M) + \boxed{i\phi(k)}] + |F(k)| \cdot \exp[-2\pi i(km/M) - i\phi(k)]] = \\ &= \frac{1}{M} \sum_{k=0}^{(M-1)/2} 2|F(k)| \cos(2\pi km/M + \phi(k)) = \frac{1}{M} \sum_{k=0}^{M-1} \boxed{|F(k)| \cos(2\pi km/M + \phi(k))}. \end{aligned}$$

**Zweidimensionale DFT einer Funktion:**

$$f : \{(m, n) \mid m = 0, 1, \dots, M-1, n = 0, 1, \dots, N-1\} \rightarrow \mathbb{R} :$$

$$F(k, l) := \sum_{m=0}^{M-1} \sum_{n=0}^{N-1} f(m, n) \cdot \exp[-2\pi i(km/M + ln/N)],$$

$$k = 0, \dots, M-1, l = 0, \dots, N-1$$

Inverse zweidimensionale DFT:

$$f(m, n) = \frac{1}{MN} \sum_{k=0}^{M-1} \sum_{l=0}^{N-1} F(k, l) \cdot \exp[2\pi i(km/M + ln/N)],$$

$$m = 0, \dots, M-1, n = 0, \dots, N-1.$$

Bem.:

periodische Fortsetzung analog wie bei 1-dimensionalem Fall



$f(m)$ und $F(k)$ bzw. $f(m, n)$ und $F(k, l)$ heißen

diskretes Fouriertransformationspaar, Schreibweise:

$$f(m) \overset{M}{\circ\!\!\!\bullet} F(k)$$

$$f(m, n) \overset{M, N}{\circ\!\!\!\bullet} F(k, l)$$

- m, n heißen **Ortskoordinaten**
- $f(m, n)$ heißt **Ortsfunktion**
- k, l heißen **Ortsfrequenzkoordinaten**
- $F(k, l)$ heißt **Ortsfrequenzspektrum**
- m - n -Ebene: **Ortsbereich**
- k - l -Ebene: **Ortsfrequenzbereich**

**Bemerkungen:**


- $F(k, l)$ ist üblicherweise komplexwertig.
- $F(k, l) = \text{Re}F(k, l) + i \cdot \text{Im}F(k, l) = |F(k, l)| \exp[i\phi(k, l)]$
- $|F(k, l)| = \sqrt{\text{Re}F(k, l)^2 + \text{Im}F(k, l)^2}$ heißt **Amplitudenspektrum**.
- $\phi(k, l) = \arctan(\text{Im}F(k, l)/\text{Re}F(k, l))$ heißt **Phasenspektrum**.
- $|F(k, l)|^2 = F(k, l) \bar{F}(k, l)$ heißt **Leistungsspektrum** von $F(k, l)$

Bem.: $\bar{} :=$ konjugiert komplex.

**Diskrete FT bei Bildern:**

Die Darstellung von Bildern im Ortsfrequenzbereich ermöglicht in vielen Fällen eine anschauliche Interpretation selbst komplizierter Sachverhalte. Dabei hilft folgende alternative Sichtweise der zweidimensionalen DFT:


Jede zweidimensionale diskrete reelle Funktion (Bild) $f(m, n)$ lässt sich als Summe von abgetasteten sinusförmigen Wellenfunktionen unterschiedlicher Amplitude und Phasenlage darstellen (M, N ungerade vorausgesetzt).



Beweis: siehe Vorlesung Digitale Bildverarbeitung

Bemerkung:

Die Wellenfront von $F(k, l)$ breitet sich in Richtung (k, l) aus,
 hat die Frequenz $\sqrt{(k)^2 + (l)^2}$,
 die Phasenverschiebung $\phi(k, l) = \arctan(\text{Im}F(k, l)/\text{Re}F(k, l))$
 und die Amplitude $|F(k, l)| = \sqrt{\text{Re}F(k, l)^2 + \text{Im}F(k, l)^2}$

**zentrierte Darstellung der DFT:**

Wahl eines anderen Ausschnitts der periodischen Fortsetzung der DFT:

zentriert um $k = l = 0$ im Intervall

$$-(M-1)/2 \leq k \leq (M-1)/2,$$


$$-(N-1)/2 \leq l \leq (N-1)/2,$$

da dem Punkt (0,0) als Mittelwert besondere Bedeutung zukommt.


Bsp.: Ortsbereich:



Frequenzbereich,
DFT, Amplitude:



zentriert, DFT, Amplitude:




logarithmische Darstellung:

$$\tilde{F}(k, l) := \log(1 + |F(k, l)|)$$


Grund: üblicherweise großer Wertebereich der DFT.

Bsp.:


**Darstellung als Rasterbild:**

$M \times N$ - Bild, wobei der Bildpunkt (i, j) einen Grauwert proportional zur logarithmisch zentrierten Darstellung an dieser Stelle bekommt.

schwarz: geringer Wert *weiß:* hoher Wert



nicht logarithmisch




logarithmisch

**Bsp.:**

Ortsbereich:




Frequenzbereich, DFT, Amplitude:



zentriert, DFT, Amplitude:



zentriert und logarithmisch, DFT:



Bem.: Der weiße vertikale Streifen entsteht durch Beschränkung des Signals auf einen endlichen Bildausschnitt.



Eigenschaften der DFT

Vertauschungssatz:

Wenn $f(m, n) \stackrel{M, N}{\circ \bullet} F(k, l)$
 dann $F(m, n) \stackrel{M, N}{\circ \bullet} MN \cdot f(M - k, N - l)$

Separierbarkeit:

$$f(m, n) \circ \bullet F_m(k, n) \circ \bullet F(k, l)$$

$$f(m, n) \circ \bullet F_n(m, l) \circ \bullet F(k, l)$$

**Faltungssatz:**

Sei $f : \{(m, n) \mid 0 \leq m \leq M_f - 1, 0 \leq n \leq N_f - 1\} \rightarrow \mathbb{R} \quad (C)$

$h : \{(m, n) \mid 0 \leq m \leq M_h - 1, 0 \leq n \leq N_h - 1\} \rightarrow \mathbb{R} \quad (C)$

$$M := M_f + M_h - 1, N := N_f + N_h - 1,$$

Dann gilt:

$$g(m, n) := f(m, n) ** h(m, n) := \sum_{\xi=0}^{M-1} \sum_{\eta=0}^{N-1} f(\xi, \eta) h(m-\xi, n-\eta)$$

$$\stackrel{M, N}{\circ \Rightarrow \bullet} G(k, l) = F(k, l) \cdot H(k, l).$$

Bem.: Die Summanden mit Faktoren außerhalb des Definitionsbereichs der Funktionen werden nicht ausgewertet.

**Vorgehensweise:**

1. Anwendung der DFT auf das gegebene Bild (mit FFT-All.)
2. Filtern im Ortsfrequenzbereich (Multiplikation)
3. Rücktransformation (mit FFT-All.).

Bsp.: Lineare Tiefpassfilter

rotationssymmetrischer idealer Tiefpass mit Bandbreite w_0 :

$$H_{\text{ITP}}(k, l) := \begin{cases} 1 & \text{für } \sqrt{k^2 + l^2} \leq w_0 \\ 0 & \text{sonst} \end{cases}$$


Gaußtiefpass:

$$H_{\text{GTP}}(k, l) = \exp[-(k^2 + l^2)/w_0^2]$$




Bsp.:


Originalbild:




Testbild: Störung durch additive Überlagerung mit starkem Gaußschen Rauschen, Standardabwe $\sigma = 50$ Intensitätseinheiten bei 8 Bit Grauauflösung:



idealer Tiefpass:




Gaußtiefpass:



Bsp.: DFT der linearen Glättungsoperatoren im Ortsbereich:

Spalttiefpass: Gaußtiefpass: Kegeltiefpass:


Ortsbereich:





Spalttiefpass: Gaußtiefpass: Kegeltiefpass:

Ortsfrequenz-
bereich:



Bsp.: Linearer Hochpassfilter im Frequenzbereich

komplementärer Anteil eines linearen Tiefpassfilters plus Gleichanteil, anschließend zurücktransformiert.

Bsp.:

Tiefpassfilterung durch Reduktion der Bandbreite auf 1/4 der maximal darstellbaren Ortsfrequenz, anschließend in den Ortsbereich zurücktransformiert:



Hochpassfilterung: komplementärer Anteil zum vorigen Beispiel + Gleichanteil, anschließend zurücktransformiert:





Fast Fourier Transformationsalgorithmus (FFT-Algorithmus)

Berechnung der DFT:

$$F(k) = \sum_{m=0}^{M-1} f(m) \exp[-2\pi i m \cdot k/M] = \sum_{m=0}^{M-1} f(m) \omega_M^{mk}, \omega_M := \exp(-2\pi i/M)$$

- mit dem Horner-Schema:

$$M \cdot O(M) = O(M^2) \quad \text{Zeitaufwand}$$

- mit dem Fast Fourier Transformationsalgorithmus (FFT-Algorithmus):

$$O(M \log M) \quad \text{Zeitaufwand}$$

Strategie der FFT: **Divide & Conquer.**

im folgenden: M Zweierpotenz (o.B.d.A.)



Es gilt: $F(k) = \sum_{m=0}^{M-1} f(m) \omega_M^{mk}$ mit $\omega_M := \exp(-2\pi i/M)$

$$\begin{aligned}
 &= \sum_{m=0, m \text{ gerade}}^{M-1} f(m) \omega_M^{mk} + \sum_{m=0, m \text{ ungerade}}^{M-1} f(m) \omega_M^{mk} \\
 &= \sum_{m=0}^{\frac{M}{2}-1} f(2m) \omega_M^{2mk} + \sum_{m=0}^{\frac{M}{2}-1} f(2m+1) \omega_M^{(2m+1)k} \\
 &= \underbrace{\sum_{m=0}^{\frac{M}{2}-1} f(2m) \omega_{M/2}^{mk}}_{F_g(k)} + \omega_M^k \underbrace{\sum_{m=0}^{\frac{M}{2}-1} f(2m+1) \omega_{M/2}^{mk}}_{F_u(k)}
 \end{aligned}$$

$\omega_M^{2mk} = \omega_{M/2}^{mk}$

$$F(k) = F_g(k) + \omega_M^k F_u(k)$$

- $F_g(k)$ die DFT der $\frac{M}{2}$ -langen **geraden** Sequenz $f(2m)$
 - $F_u(k)$ die DFT der $\frac{M}{2}$ -langen **ungeraden** Sequenz $f(2m+1)$
- über $0, \dots, M-1$

**Schwierigkeit:**

$F_g(k)$ und $F_u(k)$ müssen für $0, \dots, M-1$ ausgewertet werden

→ kein $O(n \log n)$ -Algorithmus


Lösung:

$$F(k) = \begin{cases} F_g(k) + \omega_M^k F_u(k) & \text{für } 0 \leq k \leq \frac{M}{2} - 1, \\ F_g(k - \frac{M}{2}) - \omega_M^{k - \frac{M}{2}} F_u(k - \frac{M}{2}) & \text{für } M/2 \leq k \leq M - 1 \end{cases}$$

Speziell für $M = 2$:

$$\begin{aligned} F(0) &= f(0) + f(1) \\ F(1) &= f(0) - f(1) \end{aligned}$$

Beweis: siehe Vorlesung Digitale Bildverarbeitung

**Graphische Darstellung des FFT-Algorithmus (für M=8):**

→ Zeitaufwand: $O(M \log M)$

Bemerkungen:

- inverse DFT analog mit $F^{-1}(F(f(k))) = \overline{F(\overline{F(f(k))})}/M$
- zweidimensionale DFT mit FFT in Zeit $O(M \cdot N(\log M + \log N))$

**I.1. Einleitung**

- I.1.1. Mensch-Maschine-Interaktionsmodell
- I.1.2. Eingabesensoren und Eingabegeräte
- I.1.3. Handorientierte Eingabegeräte
- I.1.4. Bewegungsverfolgung
- I.1.5. Sensordatenverarbeitung

I.2. Digitale Bildverarbeitung

- I.2.1. Einleitung
- I.2.2. Bildaufnahme
- I.2.3. Bildrestauration
- I.2.4. Bildverbesserung
 - I.2.4.1. Punktoperatoren
 - I.2.4.2. Lokale Operatoren im Ortsbereich
 - I.2.4.3. Diskrete Fouriertransformation
 - I.2.4.4. BV im Ortsfrequenzbereich
- I.2.5. Segmentierung
 - I.2.5.1. Einleitung
 - I.2.5.2. Bereichsorientierte Verfahren
 - I.2.5.3. Kantenorientierte Verfahren

I.3. Mustererkennung

- I.3.1. Grundkonzept
- I.3.2. Merkmale
- I.3.3. Klassifikation
- I.3.4. Neuronale Netze
 - I.3.4.1. Multilayer Feedforward NNs
 - I.3.4.2. Convolutional NNs
 - I.3.4.3. Sprachmodelle und GPT
 - I.3.4.4. Bemerkungen



I.4. Verarbeitung zeitabhängiger Signale

- I.4.1. Zeitabhängige Signale
- I.4.2. Filterung zeitabhängiger Signale



Segmentierung: Unterteilung von Bildern in bedeutungsvolle Teilbereiche.

Original:

Ergebnis einer
Segmentierung


Segmentierung:

Unter der Segmentierung eines diskreten Bildsignals $f(m, n)$, $0 \leq m \leq M - 1$, $0 \leq n \leq N - 1$, versteht man die Unterteilung von f , als Menge von Pixeln gesehen, in disjunkte, nichtleere Teilmengen $f_1, f_2, \dots, f_p$ so, dass mit einem zu definierenden Einheitlichkeitskriterium E gilt:


- a) $\cup_{i=1}^p f_i = f$.
- b) f_i ist zusammenhängend für alle i mit $i = 1, \dots, p$.
- c) Für alle f_i ist das Einheitlichkeitskriterium $E(f_i)$ erfüllt.
- d) Für die Vereinigung zweier benachbarter f_i, f_j ist $E(f_i \cup f_j)$ nicht erfüllt.

Einheitlichkeitskriterium:

z.B. die Intensitätsdifferenz zweier beliebiger Bildpunkte innerhalb eines Bereichs f_i darf den Wert e betragsmäßig nicht überschreiten (Kriterium der Intensitätshomogenität)


Möglichkeiten der Darstellung des Ergebnisses der Segmentierung:**Maske****Binärbild:**

Objekt $\hat{=}$ 1, sonstige
Bildpunkte = 0

Konturlinie**Binärbild:**

Randpixel $\hat{=}$ 1, sonstige
Bildpunkte = 0
→ Kettencodes

Darstellung von Konturlinien durch Kettencodes



1. Einfacher Schwellwertoperator:

$$g(m, n) = \begin{cases} I_1 & \text{für } 0 \leq f(m, n) < s \\ I_2 & \text{für } s \leq f(m, n) \leq f_{\max}. \end{cases}$$

I_1 , I_2 sind zwei beliebige, jedoch voneinander verschiedene Werte, s eine Intensitätsschranke.


Bem.:

anwendbar, wenn sich helle Objekte auf dunklem Hintergrund oder umgekehrt befinden:

Bem.:

s z.B. aus dem Histogramm bestimmbar

Bsp.:


**2. Mehrwertiger Schwellwertoperator:**

$$g(m, n) = I_i \text{ für } s_{i-1} \leq f(m, n) < s_i, \quad i = 1, 2, \dots, p$$


mit $s_0 = 0$ und $s_p = f_{\max} + 1$.

Bsp.: $p = 3$


Original:






mediangefiltert zur
Glättung bei
Kantenerhaltung:




Ergebnis:




Original:

mediangefiltert zur
Glättung bei
Kantenerhaltung:Ermittlung der
Schwellwerte aufgrund
von Histogrammtälern:


Histogramm:






Intensitätsprofil:



Original:



Günstige Schwellwerte: zu niedrige Schwellwerte: zu hohe Schwellwerte





Eigenschaften des Verfahrens:

1. Keinerlei a priori-Wissen über das Bild erforderlich.
2. Es verbleiben keine Fehlstellen.
Bei richtig gewählten Anfangspunkten ist das Verfahren extrem störungsunempfindlich.
3. Die Lagen der Kanten zwischen den Bereichen stimmen gut mit subjektiv empfundenen Kantenlagen überein.
4. Das Bereichswachstumsverfahren ist ein bottom-up-Verfahren.
Andere Möglichkeit: top-down, split & merge.




5. Unterteilungsverfahren

Strategie:

sukzessives Unterteilen des Bildes, solange bis die Teile das gegebene Einheitlichkeitskriterium E erfüllen;


Vereinigen benachbarter Teile, die das Einheitlichkeitskriterium erfüllen.

Bsp.: Quadtree-Unterteilung



Algorithmus:


1. Teile jede Region R_i , für die $E(R_i)$ nicht erfüllt ist, in 4 Quadranten auf;
2. Verschmelze alle benachbarten Regionen R_j, R_k , für die $E(R_j \cup R_k)$ erfüllt ist;
3. Ende, wenn kein weiteres Unterteilen oder Vereinigen möglich ist.




LITERATUR:
T. Pavlidis, Algorithms
for Graphics and Image
Processing,
Springer-Verlag, 1982

Kantenorientierte Bildsegmentierung:

- zwei Schritte:
1. Zuordnung eines Eigenschaftsgradienten an jeden Bildpunkt.
 2. Nachbearbeitung, z.B. Konturverfolgung.

Ermittlung der Ableitung in einer Dimension

Bezeichnung der Bildpunkte im Folgenden:



- **diskreter Gradientenvektor:**

$$\begin{pmatrix} D - A \\ B - A \end{pmatrix} \quad (\text{kontinuierlich : } \begin{pmatrix} \frac{\partial f}{\partial x} \\ \frac{\partial f}{\partial y} \end{pmatrix})$$

- **diskreter Gradient:**

$$[(D-A)^2 + (B-A)^2]^{\frac{1}{2}} \quad (\text{kontinuierlich : } [(\frac{\partial f}{\partial x})^2 + (\frac{\partial f}{\partial y})^2]^{\frac{1}{2}})$$


störend: Quadrierung, Wurzel

→ Vereinfachung: $|D - A| + |B - A|$

→ Nachteil: E wird nicht berücksichtigt

1. Lokale Gradientenoperatoren


Allgemeines Prinzip:




Anwendungsbeispiel: Die erste und dritte Zeile, durch die Summe verknüpft: ergibt den Sobel-Operator.

$$g_{SOB} = | \underbrace{(A+2B+C)}_{TP} - \underbrace{(G+2H+I)}_{TP} | + | \underbrace{(A+2D+G)}_{TP} - \underbrace{(C+2F+I)}_{TP} |$$

1. Lokale Gradientenoperatoren

Farbkodierte
Richtungsgradienten**Roberts-Gradient:**

$$g_{ROB} = \max(|A - E|, |B - D|)$$

**Sobel-Operator:**

$$g_{SOB} = |(A+2B+C)-(G+2H+I)| + |(A+2D+G)-(C+2F+I)|$$

Laplace-Operator:

Operator 2. Ordnung:


$$g_{LAP} = B+D+F+H-4E \quad (\text{kontinuierlich: } \frac{\partial^2 f}{\partial x^2} + \frac{\partial^2 f}{\partial y^2})$$

absoluter Pseudo-Laplace-Operator:


$$g_{APL} = |(D-2E+F)+(B-2E+H)| = |B+D+H+F-4E|$$

berechnet Differenzen 2. Ordnung und reagiert daher auf Krümmungen der Intensitätsfunktion sehr empfindlich.


Bsp.: ohne Rauschen: Originalbilder: mit Rauschen:




Roberts-Gradient:



ohne Rauschen: Sobel-Operator: mit Rauschen:



absoluter Pseudo-Laplace-Operator:



**Bemerkungen:**

- Roberts-Gradient verstärkt Rauschen, Sobel-Operator weniger empfindlich
- Pseudo-Laplace-Operator verstärkt Rauschen noch mehr, da von höherer Ordnung.

„Faustregel“:


Je stärker die einem Bildsignal überlagerten Störungen sind, umso ausgedehnter müssen die Einzugsbereiche des Verfahrens sein, um eine gewisse Störrobustheit zu erreichen.

**2. Konturverfolgung****Ergebnis der Kantendetektion:**

ortsdiskrete, wertkontinuierliche Gradientenbilder, die lokale Intensitätsdifferenzen 1. oder 2. Ordnung, manchmal auch die Gradientenrichtung des ursprünglichen Signals, repräsentieren.

Zweck der Konturverfolgung:

Umwandlung der i.a. mehrere Bildpunkte breiten Gradientenzüge, die evtl. auch unterbrochen sind und eventuell auch nicht zum Rand des Objekts gehören, in dünne, binärwertige Objektkonturen.



**Algorithmus:**

- Initialpunkt p festlegen, z.B. Bildpunkt mit hohem Gradientenwert
- mit p beginnend entsprechend vorgegebener **Randbedingungen an die Richtungsänderungen** einen Pfad aus Bildpunkten aufbauen, der vorgegebene **Optimierungskriterien** und problemabhängige Randbedingungen gut erfüllt.

Optimierungskriterium:

$$\text{z.B. } \prod_{i=0}^L g(i) \rightarrow \max$$

mit $g(i)$ der vom Sobeloperator am Bildpunkt i gelieferte Wert, L die Pfadlänge

**Randbedingungen an die Richtungsänderungen:**


- Zurückwandern verboten:

$$r(i-1, i) \neq [r(i, i+1) + 4] \bmod 8$$

- Krümmungsbeschränkung:

$$\min\{r, 8-r\} \leq \Delta r \text{ mit } r := |r(i-1, i) - r(i, i+1)|$$

wobei $(r(i-1, i))$ die Richtung vom $(i-1)$ -ten zum i -ten Pixel) entsprechend der rechts gezeigten Nummerierung:

**problemabhängige Randbedingungen:**

- Bildrand darf nicht erreicht werden
- geschlossene Konturen müssen erzeugt werden
- Längenbeschränkung von unten und von oben an Konturen

**Lösung:**


Lokale Optimierung auf nur $L' \ll L$ Konturpunkten.

Zusammensetzen der Gesamtkontur aus Teilpfaden der Länge L' .

Bsp.: $L' = 2, \Delta r = 1$

↪ mögliche Pfade bei der Suche der dick gezeichneten Kontur:

Einzelne Pixel können mehr als einmal innerhalb des Pfades (Kontur) mit Startpunkt x_s vorkommen und isolierte Pixel beschreiben auch eine Kontur.

**I.1. Einleitung**

- I.1.1. Mensch-Maschine-Interaktionsmodell
- I.1.2. Eingabesensoren und Eingabegeräte
- I.1.3. Handorientierte Eingabegeräte
- I.1.4. Bewegungsverfolgung
- I.1.5. Sensordatenverarbeitung

I.2. Digitale Bildverarbeitung

- I.2.1. Einleitung
- I.2.2. Bildaufnahme
- I.2.3. Bildrestauration
- I.2.4. Bildverbesserung
 - I.2.4.1. Punktoperatoren
 - I.2.4.2. Lokale Operatoren im Ortsbereich
 - I.2.4.3. Diskrete Fouriertransformation
 - I.2.4.4. BV im Ortsfrequenzbereich
- I.2.5. Segmentierung
 - I.2.5.1. Einleitung
 - I.2.5.2. Bereichsorientierte Verfahren
 - I.2.5.3. Kantenorientierte Verfahren

I.3. Mustererkennung

- I.3.1. Grundkonzept
- I.3.2. Merkmale
- I.3.3. Klassifikation
- I.3.4. Neuronale Netze
 - I.3.4.1. Multilayer Feedforward NNs
 - I.3.4.2. Convolutional NNs
 - I.3.4.3. Sprachmodelle und GPT
 - I.3.4.4. Bemerkungen

Muster:


Zusammenfassung der gemessenen Werte einer einzelnen Stichprobe aus einem begrenzten Ausschnitt der Welt.

Mustererkennung:


Zuordnung einer solchen Stichprobe an eine von mehreren Klassen.

Quellen


- Niemann: Klassifikation von Mustern. 2. überarbeitete Auflage im Internet, 2003.
- Duda, Hart, Stork, Pattern Classification (2nd ed.), John Wiley & Sons, NY, Oct. 2000
- Goodfellow, Bengio, Courville: Deep Learning (<http://www.deeplearningbook.org>)
- Bishop: Pattern Recognition and Machine Learning (<http://www.springer.com/gp/book/9780387310732>)

Ablauf im Detail:


Bsp.:




Bsp.:




Pinienkerne, Linsen und Kürbiskerne



Zwei Merkmale: Kreisförmigkeit und Linienanpassungsfehler



Grundkonzept der Mustererkennung



- **Merkmal:**
Kenngroße, die einem Muster zugeordnet wird
- **Ziel:**
möglichst wenige Merkmale finden, die die eindeutige Klassifikation des gegebenen Musters erlauben, d.h. die Dimension des Merkmalsraums soll klein gehalten werden.
- **Merkmalstypen:**
numerische Merkmale: Zahl → "Statistik"
symbolische Merkmale: Zeichenketten → "KI"
- **Klassifikationsraum:**
besteht aus in der Regel disjunkten Klassen, in die eine Kombination von Merkmalen durch die Klassifikation abgebildet wird.
- **Ausprägungen von Merkmalen:**
z.B. Fläche, Umfang, größeninvarianter Formfaktor, Krümmung an Objekträndern, Fourier-Deskriptor, Momente

Fläche:

Anzahl der Pixel der Objekte

Umfang:

- Heuristik: Abzählen von benachbarten Punktepaaaren (p, q) ,
 p Hintergrundpixel, q Objektpixel
- Heuristik: Konturverfolgung mit Längeneinheit 1 für horizontale/vertikale Fortschreitung und $\sqrt{2}$ für diagonale Fortschreitung.

größeninvarianter Formfaktor:

$$S := \frac{U^2}{4\pi F}, \quad U \text{ Umfang, } F \text{ Fläche}$$

Bem.: $S = 1$ für kreisförmige Objekte, S groß für linienhafte Objekte.

Krümmung an Objekträndern:

Krümmung an einem Punkt p_i :

Winkeldifferenz der Geraden durch die beiden Punktepaaare

(p_{i-1}, p_i) , (p_i, p_{i+1}) , wobei p_{i-1} , p_{i+1} Objektrandpunkte, die zu p_i benachbart sind.

k-Krümmung an einem Punkt p_i :

Winkeldifferenz der Geraden durch die beiden Punktepaaare

(p_{i-k}, p_i) , (p_i, p_{i+k}) , wobei p_{i-k} , p_{i+k} die k -nächsten Nachbarn auf der Kontur.

Maße:



Mittelwert der $(k-)$ Krümmung als Maß für die Krümmung linienförmiger Objekte bzw. Ausgefranstheit der Objektränder.

Histogramm anstatt Mittelwert.

Fourier-Deskriptor:

Eingabe: Objektrand durch Q Konturpunkte (x_i, y_i) , $i = 0, \dots, Q - 1$.

Ausgabe: alle oder ein Teil der Koeffizienten der DFT von
 $f: \{0, 1, \dots, Q - 1\} \rightarrow \mathbb{C}$ mit $f(j) := x_j + i \cdot y_j$

**Bsp.: Approximative Beschreibung von Flugzeugsilhouetten:****Berechnung der Bilder:**

- Berechnung von F aus dem Originalrand (512 Punkte)
- Beschränkung auf die 32 Koeffizienten geringster Frequenz, d.h. die anderen werden zu 0 gesetzt
- inverse Fouriertransformation





Bemerkung:

Häufig werden mehrere Merkmale kombiniert. Diese hängen jedoch im Allgemeinen voneinander ab, sodass die resultierenden Merkmalsvektoren mit Redundanz behaftet sind.

Die Abhängigkeit kann mittel der sogenannten Hauptachsentransformation (auch Principal Component Analysis – PCA oder Karhunen-Loève-Transformation genannt) analysiert und darauf aufbauend häufig eine Dimensionsreduktion des Merkmalsraums erreicht werden.

Ursprung des Hauptachsenkoordinatensystems: Schwerpunkt der gegebenen Punkte;

Koordinatenachsen: Normalen der lokalen Optima des Ausgleichsebenenproblems.

Bsp.: Ausgleichsgerade**Bsp.: Hauptachsenkoordinatensystem****Bsp.: Dimensionsreduktion****Allgemeines Prinzip der Klassifikation**

Lernkonzepte


- **Überwachtes Lernen (Supervised learning)**
 - Lernen der Modellparameter anhand eines Datensatzes von Daten-Label-Paaren
 - Beispiele: Klassifizierung, Regression, strukturierte Vorhersage
- **Unüberwachtes Lernen (Unsupervised learning)**
 - Lernen von Modellparametern anhand eines Datensatzes ohne Labels
 - Beispiele: Clustering, Dimensionsreduktion, generative Modelle
- **Selbst-überwachtes Lernen (Self-supervised learning)**
 - Lernen von Modellparametern anhand eines Datensatzes von Daten-Daten-Paaren
 - Beispiele: Self-supervised stereo/Flow, Kontrastives Lernen
- **Verstärkungslernen (Reinforcement learning)**
 - Lernen von Modellparametern mittels aktiver Exploration aus spärlichen Belohnungen
 - Beispiele: Deep Q Learning, Gradient Policy, Actor Critique


Unüberwachtes Lernen

ISODATA-Clustering


1. Bestimme Anfangszahl k von Klassen, Startwerte $\mathbf{a}_{k0}$, $k = 1, \dots, k$, und Kostenfunktion S .
2. Wähle eine Stichprobe $\mathbf{c}$ und klassifiziere sie nach Ω_k , wenn $S(\mathbf{c}, \mathbf{a}_k) = \min_{\lambda} S(\mathbf{c}, \mathbf{a}_{\lambda})$.
3. Berechne neue Parameter $\mathbf{a}_{ki}$, $k = 1, \dots, k$.
4. Wenn eine Klassen zu inhomogen, zerlege sie in zwei neue Klassen
5. Wenn eine Klassen zu wenig Muster enthält, eliminiere sie.
6. Wenn zwei Klassen zu dicht benachbart sind, vereinige sie.
7. Wenn die in 3. berechneten Parameter nicht mit den alten übereinstimmen, dann $\rightarrow$ 2.

Bsp.: $S(\mathbf{c}, \mathbf{a}_k) = \text{Distanz zwischen } \mathbf{c}, \text{ und } \mathbf{a}_{\lambda}$, wobei $\mathbf{a}_{\lambda}$ in Ω .




Überwachtes Lernen

- **Lernen:** Schätzen der Parameter $\mathbf{w}$ aus den Trainingsdaten $\{(x_i, y_i)\}_{i=1}^N$
- **Inferenz:** Neue Vorhersagen ableiten: $y = f_{\mathbf{w}}(x)$

Klassifikation


- **Mapping:** $f_{\mathbf{w}}: \mathcal{R}^{W \times H} \rightarrow \{\text{„Strand“}, \text{„kein Strand“}\}$

Regression



- Mapping: $f_w: \mathcal{R}^N \rightarrow \mathcal{R}$


„Strukturierte Prädiktionen“




- Mapping: $f_w: \mathcal{R}^{W \times H} \rightarrow \{1, \dots, C\}^{W \times H}$

Learnkonzepte und Merkmale

- Traditionelle Mustererkennung



- End-to-End-Lernen → Merkmale werden auch aus Daten gelernt



Neuronale Netze und Deep Learning - kompakt

- Eine Gruppe parametrischer, nicht linearer und hierarchischer Funktionen des Repräsentationslernes, die mit stochastischem Gradientenabstieg massiv optimiert werden, um Domänenwissen, d.h. Domäneninvarianzen, zu kodieren.

$$a_L(x; \theta_{1,...,L}) = h_L(h_{L-1}(\dots h_1(x, \theta_1), \theta_{L-1}), \theta_L)$$


Eingabe: x Parameter pro Layer l : θ_l (nicht-)lineare Funktion: $a_l = h_l(x, \theta_l)$

- Ermittlung der optimalen Parameter auf Basis einer Trainingsmenge $\{X, Y\}$

$$\theta^* \leftarrow \arg \min_{\theta} \sum_{(x,y) \in (X,Y)} \ell(y, a_L(x; \theta_{1,...,L}))$$

Multilayer Feedforward Neuronal Networks (MFNN)


Architektur




Eingabe: ein Merkmalsvektor

Ausgabe: ein Klassenvektor mit der Länge der Anzahl der Klassen;
jede Vektorkomponente entspricht einer Klasse, die Konfidenz für
die Zugehörigkeit zu der Klasse ausdrücken kann

Neuron



Neuron

Connection: gewichtete Summe der Eingabewerte

$$\hat{\mathbf{x}}^{(l)} = \mathbf{W}^{(l)} * \mathbf{x}^{(l-1)}, \quad \mathbf{W}^{(l)} \in \mathbb{R}^{N^{(l-1)} \times N^{(l)}}$$

Bias: Verschiebung der Aktivierungsfunktion gegen den Ursprung

$$\hat{\mathbf{x}}^{(l)} = \hat{\mathbf{x}}^{(l)} - \mathbf{b}^{(l)}, \quad \mathbf{b}^{(l)} \in \mathbb{R}^{N^{(l)}}$$

Aktivierungsfunktion: σ Steuerung der Ausgabe in Abhängigkeit des Wertes der Connection

$$\mathbf{x}^{(l)} = (x_j^{(l)}), \quad x_j^{(l)} = \sigma(\hat{x}_j^{(l)}), \quad j = 1, \dots, N^{(l)}, \quad \hat{\mathbf{x}}^{(l)} = (\hat{x}_j^{(l)})$$


Aktivierungsfunktionen

$$\sigma_{\text{sigmoid}}(x) := \frac{1}{1 + e^{-x/\theta_0}}, \quad \theta_0 > 0$$

$$\sigma_{\text{tanh}}(x) := \tanh(x) = \frac{e^{2x} - 1}{e^{2x} + 1}$$

$$\sigma_{\text{relu}}(x) := \max(0, x)$$

$$\sigma_{\text{elu}}(x) := \max(0, x) + \min(0, \alpha \cdot (e^x - 1)), \quad \alpha \geq 0$$





Klassifikation

Ansätze für die Klassifikation:

- Zuordnung des Eingabevektors zu der Klasse, deren zugeordnete Vektorkomponente einen gegebenen Schwellwert überschreitet; Anwendung insbesondere in dem Fall, dass der Wert der Ausgabe durch 1 beschränkt ist, wie etwa bei der Sigmoid-Funktion.
- Zuordnung des Eingabevektors zu der Klasse, deren zugeordnete Vektorkomponente maximal unter allen Vektorkomponenten ist.
- Anfügen einer weiteren vollverbundenen Schicht, deren Endneuronen die sogenannte Softmax-Funktion

$$\text{softmax}(y_j) = \frac{y_j}{\sum_{k=1}^C y_k}$$

berechnen, wobei C die Anzahl der Klassen.

Auswahl der Klasse mit maximaler Vektorkomponente.



Anlernen

Bestimmung der Gewichtswerte und der Bias-Werte, zusammengefasst in einen Vektor θ , durch überwachtes Lernen anhand von Trainingsdaten, deren Klassenzuordnung bekannt ist.

Vorgehensweise:

- Wiederholtes Abarbeiten der Trainingsdaten in sogenannten **Epochen**
- In jeder Epoche iterierte Durchführung eines **Trainingsschritts** für eine Folge der Trainingsdaten bzw. eine Folge von Teilmengen (**Batches**) der Trainingsdaten.



Trainingsschritt beim sequentiellen Lernen:

Minimierung einer sogenannten Loss-Funktion (Fehlerfunktion)

$$L(\mathbf{y}(\mathbf{x}), \hat{\mathbf{y}}(\mathbf{x}; \theta))$$

welche die Abweichung zwischen der korrekten Klassenzuordnung $\mathbf{y}(\mathbf{x})$ für eine Eingabe $\mathbf{x}$ und der vom neuronalen Netz bestimmten $\hat{\mathbf{y}}(\mathbf{x}, \theta)$ Klassenzuordnung über θ minimiert :

$$\min_{\theta} L(\mathbf{y}(\mathbf{x}), \hat{\mathbf{y}}(\mathbf{x}; \theta))$$

Trainingsschritt beim Batch-Lernen:

Minimierung der Fehlerfunktion

$$L(\mathcal{B}; \theta) = \sum_{\mathbf{x} \in \mathcal{B}} L(\mathbf{y}(\mathbf{x}), \hat{\mathbf{y}}(\mathbf{x}; \theta)) .$$

wobei $\mathcal{B}$ ein Batch bezeichnet:

$$\min_{\theta} L(\mathcal{B}; \theta) .$$



Lösung des Minimierungsproblems:

Iterierter **Gradientenabstieg**:

$$\theta' = \theta - \eta \cdot \nabla_{\theta}^* L(\mathcal{B}; \theta) .$$

wobei

$\eta > 0$ die Lernrate,

$\nabla_{\theta}^* L(\mathcal{B}; \theta)$ der transponierte Gradienten von $L(\mathcal{B}; \theta)$
d.h. der transponierte Vektor der partiellen Ableitungen dieser Funktion.

Realisierung des Gradientenabstiegs durch sogenanntes **Backpropagation**.




Vorbereitungsschritte


1. Aufteilen der Daten
2. Datenvorverarbeitung (Data Preprocessing)
3. Ermittlung der „geeigneten“ Architektur
4. Initialisierung der Gewichte
5. Ermittlung der „geeigneten“ (Hyper-)Parameter



1. Aufteilen der Daten




2. Datenvorverarbeitung (Data Preprocessing)



2. Datenvorverarbeitung (Data Preprocessing)


Datenaugmentierung

- Erweiterung
- Diversifizierung





5. Ermittlung der „geeigneten“ (Hyper-)Parameter

u.a. Lernrate



Convolutional Neural Networks (CNNs, „Faltungsnetze“)





Convolutional Neural Networks (CNNs, „Faltungsnetze“)**Bildklassifikation****Eingabe:** ein RGB-Bild fester Größe**Ausgabe:** Klassifikation des Bildes in eine von mehreren gegebenen Klassen.


- $10^6 * 10^5 = 10^{11} = 100$ Milliarden Kanten/Gewichte
- Deep Learning: Vielfache
- Hoher Trainingsaufwand

Convolutional Neural Networks (CNNs, „Faltungsnetze“)


- Spezielle Form von neuronalen Netzen für Daten mit Gittertopologie
- Lokal verbundenes Netz
- Convolution(Faltung) statt Matrixmultiplikation



Allgemeiner Aufbau eines CNN



Convolutional Layer (Faltungsschicht): Connection durch Faltung

**Eingabe:** ein Tensor

$$\mathbf{F}^{(l-1)} \in \mathbb{R}^{W \times H \times M_{in}},$$

der eine $W \times H$ -Matrix aus Merkmalsvektoren der Dimension M_{in} repräsentiert.


Ausgabe: ein Tensor

$$\mathbf{F}^{(l)} \in \mathbb{R}^{W \times H \times M_{out}},$$

der eine $W \times H$ -Matrix aus Merkmalsvektoren der Dimension M_{out} repräsentiert und durch Anwendung der Faltungsoperation berechnet wird.

Faltungsoperator

Faltung: $s(t) = (x * w)(t) = \sum_{a=-\infty}^{\infty} x(a)w(z-a)$



$$I \in \mathbb{K}^{m \times n}, K \in \mathbb{K}^{k \times k}$$

$$\Rightarrow K * I \in \mathbb{K}^{(m-k+1) \times (n-k+1)}$$

$$I \in \mathbb{K}^{3 \times 4}, K \in \mathbb{K}^{2 \times 2}$$

$$\Rightarrow K * I \in \mathbb{K}^{2 \times 3}$$

Faltungsoperator

Beispiel

Input I

10	10	10	0	0	0
10	10	10	0	0	0
10	10	10	0	0	0
10	10	10	0	0	0
10	10	10	0	0	0
10	10	10	0	0	0

Kern K

1	0	-1
1	0	-1
1	0	-1

 $K * I$

Output S

0	30	30	0
0	30	30	0
0	30	30	0
0	30	30	0

Erweiterungen

Padding:

Hinzufügen eines Randes aus Nullen

→ Beibehalten der Größe

0	0	0	0	0
0				0
0				0
0				0
0	0	0	0	0


Strided Convolution:

Größere Schritte des Kerns über die Input Matrix

→ Kleinerer Output

Convolutional Layer

Beispiel:



Berechnung der Connection:

$$F_{i,j,m_{out}}^{(l)} = \sum_{m_{in}=1}^{M_{in}} \sum_{p=1}^{f_W} \sum_{q=1}^{f_H} W_{p,q,m_{in},m_{out}}^{(l)} F_{i-[f_W/2]+p, j-[f_H/2]+q, m_{in}}^{(l-1)}, m_{out} = 1, \dots, M_{out}$$


mit $\mathbf{W}^{(l)} = (W_{p,q,m_{in},m_{out}}^{(l)})$ ein Gewichtstensor.

Bemerkungen

- 1) Die angegebene Formel entspricht einer Kreuzkorrelation. Sie kann als Faltungsoperation realisiert werden.
- 2) Eine Variante besteht darin, die Indizes i und j zwischen 1 und W bzw. 1 und H nicht um 1, sondern mit einer Schrittweite (**Stride**) größer als 1 hochzuzählen. Dadurch reduziert sich die Größe der Ausgabe entsprechend.


Pooling

- Häufig: Max Pooling (Maximum in Umgebung)



- Ersetzt den Output des Netzes an einer bestimmten Stelle durch eine zusammenfassende Statistik der benachbarten Outputs
- Reduziert die Dimension
- Reduziert auf wesentliche Informationen


Fully Connected Layer (vollständig verbundene Schicht)



Funktionsweise:

- Verbindung eines Neuron mit allen seinen Vorgängerneuronen (siehe MFNN).
- Ermittlung der Eingabe (Connection) eines Neurons als gewichtete Summe aller seiner Ausgaben, wobei alle Gewichte unterschiedlich sein können.


U-Net




VGG-16 net

Eingabe: ein 224x224 RGB-Bild


Ausgabe: Klassifikation des Bildes in eine von 1000 Klassen


<https://www.cs.toronto.edu/~frossard/post/vgg16/>


VGG-16-Net – Convolutional Block (Merkmalsextraktion)


<https://learnopencv.com/understanding-convolutional-neural-networks-cnn>

VGG-16-Net – Fully Connected Classifier (Klassifikation)




VGG-16-Net – Fully Connected Classifier (Klassifikation)



- **Natural Language Processing (NLP):** Maschinelles Analysieren, Transformieren und Generieren von natürlicher Sprache
- **Large Language Models (LLM):** LLMs basieren auf KNN, sind spezialisiert auf das Gebiet von NLP
- **Generative Pre-Trained Transformer (GPT):** GPT, z.B. Chatbot ChatGPT und Modellen wie GPT-4 von OpenAI, sind Beispiele für ein LLM
- **Tokens:** In ganze Zahlen umgewandelte Worte oder Wortbestandteile durch ein LLM, wobei jedem Wort eine feststehende Zahl zugewiesen ist. Wenn LLMs Sprache verarbeiten oder generieren, verarbeiten sie Tokens und generieren Tokens, die am Ende wieder in Worte umgewandelt werden.
- **Kontext-Fenster** (Context Window): Umfasst bei LLMs den Kontext eines aktuell zu generierenden Wortes. Da LLMs immer nur das nächste Wort vorhersagen, geschieht diese Vorhersage unter Einbezug aller vorher geschriebenen Worte (Tokens), inklusive der Eingabe. Kontext-Fenster fungiert somit wie der Arbeitsspeicher eines LLM.

Sprachmodelle



Suchmodelle




Herausforderungen bei der Sprachverarbeitung

- Bedeutung der Wortreihenfolge
 - (1) Wir haben für die Prüfung **besser** gelernt.
 - (2) **Besser**, wir haben für die Prüfung gelernt.
- Bedeutung der Wörter im Kontext/Sinnzusammenhang
 - (1) Wir **fliegen** heute nach Hamburg.
 - (2) Der Raum ist voller **Fliegen**.


Anforderungen an die Modellarchitektur zur Text-/Sprachverarbeitung

- Sequenzielle Verarbeitung von Wörtern
- Verarbeitung erfolgt nicht unabhängig voneinander
- Satzlänge ist variabel



→ **Rekurrente Netze**

Rekurrente Netze



Ausgabe $y_t = f_{W_{hy}}(h_t)$ resultiert aus der Verarbeitung einer Folge von Vektoren (Wörtern) x über eine Rekursionsformel $h_t = f_W(h_{t-1}, x_t)$ pro Zeitschritt t .


Nachteile von RNNs:

- begrenzte Textlänge
- keine Parallelisierung
- verschwindende Gradienten
- keine globalen Zusammenhänge


→ GPT

„Generative Pre-trained Transformer“

GPT: zeitliche Entwicklung




GPT: Entwicklung von Varianten




Sprachmodell: Wahrscheinlichkeitsverteilung von Textsequenzen

1. Anwendung: Wahrscheinlichkeit von Texten berechnen



2. Anwendung: Texte komplettieren / generieren



Sprachmodell

„Bi-Gramm“: einfaches Sprachmodell zur Wahrscheinlichkeit von Wortpaaren
→ **Lernen des Sprachmodells**

Es war einmal ein kleines Mädchen, dem war Vater und Mutter gestorben, und es war so arm, dass es kein Kämmerchen mehr hatte darin zu wohnen und kein Bettchen mehr darin zu schlafen und endlich gar nichts mehr als die Kleider auf dem Leib und ein Stückchen Brot in der Hand, das ihm ein mitleidiges Herz geschenkt hatte. Es war aber gut und fromm...

(Auszug aus "Die Sterntaler", Gebrüder Grimm)

Wort 1	Wort 2	Anzahl
<Satzanfang>	Es	512
<Satzanfang>	Und	127
<Satzanfang>	Sie	201
...	...	...
Es	war	489
Es	schrie	67
Es	konnte	153
...	...	...

Sprachmodell

„Bi-Gramm“: einfaches Sprachmodell zur Wahrscheinlichkeit von Wortpaaren
→ **Anwenden des Sprachmodells**

Wort 1	Wort 2	Anzahl	Wahrsch.
<Satzanfang>	Es	512	0,256
<Satzanfang>	Und	127	0,064
<Satzanfang>	Sie	201	0,101
...	...	...	...
Es	war	489	0,122
Es	schrie	67	0,015
Es	konnte	153	0,043
...	...	...	...



Sprachmodell

„Bi-Gramm“: einfaches Sprachmodell zur Wahrscheinlichkeit von Wortpaaren

→ **Anwenden des Sprachmodells**

Wort 1	Wort 2	Anzahl	Wahrsch.
<Satzanfang>	Es	512	0,256
<Satzanfang>	Und	127	0,064
<Satzanfang>	Sie	201	0,101
...	...	...	...
Es	war	489	0,122
Es	schrie	67	0,015
Es	konnte	153	0,043
...	...	...	...

Sprachmodell

„Bi-Gramm“: einfaches Sprachmodell zur Wahrscheinlichkeit von Wortpaaren

Probleme dieses Sprachmodells

- Jedes Wort hängt nur von seinem direkten Vorgänger ab
→ keine Konsistenz im Satz / über Sätze hinweg
- Unbekannte Worte können nicht verarbeitet werden
- Keine semantische Bedeutung


Ich packe meinen Urlaub habe
ich gehe durch ständige...

Prompt: Ich gehe heute...
Sprachmodell: heute????


Ich sitze auf einer Bank und
raube sie aus.

GPT: modernes Sprachmodell**Grundkonzepte:**



- **Transformer-Architektur**
 - Autoencoder-Prinzip
 - Positional Encodings
 - Self-Attention Mechanismus
 - Hierarchische Struktur
- **Generative Pre-Training**

**GPT:** modernes Sprachmodell**Grundkonzepte:**


- **Transformer-Architektur**
 - Autoencoder-Prinzip
 - Positional Encodings
 - Self-Attention Mechanismus
 - Hierarchische Struktur
- **Generative Pre-Training**



Autoencoder



Autoencoder





Eingabekodierung

- 1) **Worteinbettungen**
- 2) **Positionseinbettung**

Berücksichtigung semantischer Bedeutungen
besondere durch „Embeddings“
(Vektor-Repräsentation von Worten)

Beispiel: Korrelationen/Abstände





Eingabekodierung

- 1) **Worteinbettungen**
- 2) **Positionseinbettung**

Berücksichtigung semantischer Bedeutungen
besondere durch „Embeddings“
(Vektor-Repräsentation von Worten)

Beispiel: Semantische Relationen



Semantic Word Embeddings


Eigenschaften eines Word Embedding (hier Word2Vec)

- Ziel: Vektorisierung von Token (Worten)
- Erstellung: Machine Learning Verfahren
- Funktion: Abbildung von Token aus Korpus (hier Wikipedia) in hochdimensionalen abstrakten Vektorraum (hier 200dim)
- Semantische Nähe von Worten -> Vektordistanz
- „Rechnen“ im Embedding Space möglich:
 $emb(„king“) - emb(„man“) + emb(„woman“) \approx emb(„queen“)$
 => Embedding erhält bzw. enthält Semantik!




Semantic Word Embeddings


z.B. Word2Vec



Männlich - Weiblich




Verb - Zeitform




Land - Hauptstadt

Self Attention

- Berücksichtigung großer Texte als Kontext
- Bedeutung von Wörtern zur Generierung der nächsten Ausgabe



Self Attention







Fig. A Multiscale Visualization of Attention in the Transformer Model

Pretrained LLMs – Transfer Learning / Fine Tuning

Transfer-Learning:
„Weltwissen“ in Form von vortrainierten Modellen
wird als Basis genutzt und domänen- oder Use-
Case-spezifisches Wissen hinzugelernt bzw. auf
dieses eingeschränkt.



GPT-Training

Phase 1: Generative Pretraining


- ⇒ Alignment Problem: Stochastische Ergänzungen auf Basis des Textkorpus ergeben nicht zwangsläufig „gute“ Dialoge:
Bsp:
User: Wie funktioniert ein Verbrennungantrieb?
AI: Wie funktioniert ein Elektroantrieb?

Phase 2: Supervised Finetuning


- ⇒ Finetuning des Basismodells mit vorgefertigten, idealen Dialogen
- ⇒ Verbleibendes Problem:
Im Prediction-Mode beeinflusst das Model selbst den Verlauf, dadurch kommt es zu unerwarteten und dann fehlerhaften Dialogverläufen

Phase 3: Reinforcement Learning from Human Feedback

- ⇒ Selbstverstärkende Verbesserung durch Finetuning mittels eines separat trainierten Reward-Modells, welches auf menschlichem Feedback basiert (binär oder Ranking)




Reinforcement Learning (RL)




Reward-Funktion trainiert auf menschlichem Feedback

Hierarchische Struktur



Hierarchische Struktur (z.B. 2 Encoder, 1 Decoder)



LLMs – Aktuelle Schwächen

- **Token-Limit** (Feste Obergrenze der Eingabesequenz)
- Keinerlei immanente **Konsistenz- oder Korrektheitsmechanismen**.
- Ethisches **KI-Alignment** schwierig/aufwändig. Anfällig für unerwünschte „Rollenspiele“.
- Transformer haben **kein Gedächtnis**: Die Dialoghistorie wird bei jedem Dialogschritt aufs Neue eingespeist. => das „Gedächtnis“ reicht genau über eine Session.
- Wissensstand durch **Trainingsdaten und –Zeitpunkt** determiniert.
- **Halluzination** (bei Nicht-Wissen)



EU AI Act**Europäisches Gesetz über künstliche Intelligenz (KI)**<https://www.eylaw.at>**Software-Bibliotheken****Tensorflow**

- ursprünglich vom Google-Brain-Team für den Google-internen Bedarf entwickelt
- später unter der Apache-2.0-Open-Source-Lizenz veröffentlicht.

<https://www.tensorflow.org/>**Keras**

- eine Open Source Deep-Learning-Bibliothek in Python, initiiert von François Chollet
- bietet eine einheitliche Schnittstelle für verschiedene Backends, darunter TensorFlow.

<https://keras.io/>

Software-Bibliotheken

Pytorch

- eine auf maschinelles Lernen ausgerichtete Open-Source-Programmbibliothek für die Programmiersprache Python
- basierend auf der in Lua geschriebenen Bibliothek Torch.
- entwickelt vom Facebook-Forschungsteam für künstliche Intelligenz.

<https://pytorch.org/>

Literatur

- Ian Goodfellow and Yoshua Bengio and Aaron Courville: „Deep Learning“, MIT Press, 2016, Online-Version: [http:// www.deeplearningbook.org](http://www.deeplearningbook.org)
- Michael Nielsen: “Neural Networks and Deep Learning”, Online-Buch: <http://neuralnetworksanddeeplearninl.com>